

Prática 3: Comparação de K Amostras Independentes

ANOVA de um fator, ANOVA de Welch, Kruskal-Wallis e Mediana de Mood

Nathan Cordeiro Ginak e Rodrigo Caldiron

Objetivo

Neste laboratório, vamos comparar quatro procedimentos para o problema de **K amostras independentes**:

- a **ANOVA de um fator**, na sua forma clássica;
- a **ANOVA de Welch**, versão que não supõe variâncias iguais;
- o teste de **Kruskal-Wallis**;
- o teste da **Mediana de Mood**.

O objetivo é entender:

- qual característica das populações cada procedimento compara;
- o que acontece quando normalidade, homocedasticidade e balanceamento falham;
- como o **tamanho** (probabilidade de rejeitar H_0 quando ela é verdadeira) e o **poder** (probabilidade de rejeitar H_0 quando ela é falsa) de cada teste mudam com o cenário;
- por que “não-paramétrico” não é sinônimo de “sem suposições” nem de “menos poder”.

Nesta prática, vocês devem escrever os próprios códigos em **R**. O foco, contudo, não é apenas programar: cada resultado precisa ser interpretado estatisticamente.

Revisão curta: o que cada procedimento compara?

Considere k populações independentes e amostras de tamanhos $n_1, \dots, n_k$, com $N = \sum_i n_i$.

ANOVA de um fator

A ANOVA clássica investiga

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k \quad \text{versus} \quad H_1 : \text{pelo menos uma média difere,}$$

comparando a variabilidade **entre** grupos com a variabilidade **dentro** dos grupos:

$$F = \frac{\text{QM}_{\text{entre}}}{\text{QM}_{\text{dentro}}}, \quad \text{QM}_{\text{dentro}} = \frac{\sum_{i=1}^k (n_i - 1) s_i^2}{N - k}.$$

A distribuição nula $F_{k-1, N-k}$ depende de três suposições: observações independentes, erros normais e **variâncias iguais** nos k grupos. Repare que $\text{QM}_{\text{dentro}}$ é uma estimativa **única e comum** da variância: todos os grupos são obrigados a contribuir para a mesma estimativa.

ANOVA de Welch

A **ANOVA de Welch** é a adaptação da ANOVA de um fator para o caso em que as variâncias populacionais **não** são iguais. Ela não apareceu na Batalha 5, então vale entender a ideia antes de usá-la.

O ponto de partida é exatamente o mesmo do teste t de Welch para duas amostras: se um grupo é muito mais variável que os outros, não faz sentido obrigá-lo a entrar em uma estimativa comum de variância. Em vez disso, cada grupo recebe um **peso** inversamente proporcional à sua própria variância estimada,

$$w_i = \frac{n_i}{s_i^2}, \quad W = \sum_{i=1}^k w_i,$$

de modo que grupos com muita variabilidade — ou com poucas observações — pesam menos na comparação. A média global simples é substituída por uma **média ponderada**

$$\tilde{y} = \frac{1}{W} \sum_{i=1}^k w_i \bar{y}_i,$$

e a estatística compara os desvios $\bar{y}_i - \tilde{y}$ ponderados pelos mesmos pesos:

$$F_W = \frac{\frac{1}{k-1} \sum_{i=1}^k w_i (\bar{y}_i - \tilde{y})^2}{1 + 2(k-2) \Lambda}, \quad \Lambda = \frac{1}{k^2 - 1} \sum_{i=1}^k \frac{(1 - w_i/W)^2}{n_i - 1}.$$

A distribuição nula de F_W não é exatamente uma F ; usa-se a aproximação

$$F_W \stackrel{\text{aprox.}}{\sim} F_{k-1, \nu_2}, \quad \nu_2 = \frac{1}{3\Lambda},$$

em que ν_2 é um número de graus de liberdade em geral **fracionário**, obtido por uma aproximação de Satterthwaite — a mesma ideia que produz graus de liberdade quebrados no teste t de Welch.

Três observações importantes:

1. A hipótese nula continua sendo $H_0 : \mu_1 = \dots = \mu_k$. Welch é um procedimento **sobre médias**, assim como a ANOVA clássica.
2. Quando as variâncias são de fato iguais, Welch perde muito pouco em relação à ANOVA clássica. Quando não são, ele costuma controlar o nível bem melhor, sobretudo com **grupos desbalanceados**.
3. Welch **não** corrige assimetria nem caudas pesadas. Ele resolve um problema específico — variâncias desiguais — e apenas esse.

Em R, basta trocar um argumento:

```
oneway.test(y ~ grupo, data = dados, var.equal = TRUE) # ANOVA clássica
oneway.test(y ~ grupo, data = dados, var.equal = FALSE) # ANOVA de Welch
```

Teste de Kruskal-Wallis

Kruskal-Wallis substitui as observações por seus **postos** no conjunto combinado das N observações e compara a média dos postos entre os grupos:

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k n_i \left(\bar{R}_i - \frac{N+1}{2} \right)^2, \quad H \stackrel{\text{aprox.}}{\sim} \chi_{k-1}^2.$$

Na sua formulação geral, a hipótese nula é que as k **distribuições** são iguais. Para que a rejeição seja lida como diferença de **localização**, é preciso supor adicionalmente que as distribuições têm a mesma forma e a mesma dispersão, diferindo no máximo por um deslocamento.

Teste da Mediana de Mood

O teste de Mood calcula a **mediana global** $\hat{m}$ das N observações, classifica cada observação como acima ou não acima de $\hat{m}$, monta uma tabela de contingência $k \times 2$ e aplica um teste qui-quadrado de independência. Ele compara **medianas** e usa muito menos informação dos dados: de cada observação, aproveita apenas a sua posição relativa a $\hat{m}$.

i Nota

Ao longo da prática, evite dizer apenas “os testes deram resultados diferentes”. A pergunta correta é: **os quatro procedimentos estão respondendo à mesma pergunta estatística?**

Parte 1: Análise de um experimento real

O experimento

Uma rede de *fast food* introduziu um novo item no cardápio e precisava decidir qual campanha de marketing usaria no lançamento nacional. Foram definidas **três promoções** e, em um teste de mercado, cada **loja** participante foi **designada aleatoriamente** a uma das três. As vendas do novo item foram registradas durante as **quatro primeiras semanas** de campanha.

Trata-se, portanto, de um **experimento completamente aleatorizado com um fator** (a promoção) e **três tratamentos**. A unidade experimental é a loja.

Os dados estão disponíveis no Kaggle:

Fast Food Marketing Campaign A/B Test — <https://www.kaggle.com/datasets/chebotinaa/fast-food-marketing-campaign-ab-test> (origem: conjunto de exemplo do IBM Watson Analytics)

Baixe o arquivo pela plataforma ou use a cópia disponibilizada com esta prática, `dados_pratica03.csv`. As variáveis são:

Variável	Descrição
MarketID	identificador do mercado
MarketSize	porte do mercado: Small, Medium, Large
LocationID	identificador da loja
AgeOfStore	idade da loja, em anos
Promotion	promoção aplicada: 1, 2 ou 3
week	semana de campanha: 1 a 4
SalesInThousands	vendas do novo item, em milhares de dólares

A pergunta de interesse é:

Há evidências de que as três promoções diferem quanto às vendas do novo item?

Tarefa 0: unidade experimental e independência

Antes de qualquer teste, responda:

1. Leia o arquivo e verifique quantas linhas ele tem e quantas lojas distintas (**LocationID**) aparecem. O que explica a diferença entre esses dois números?

```
db <- read_csv("dados_pratica03.csv")
linhas <- nrow(db)
lojas_distintas <- unique(db$LocationID) %>% length()
```

Existem 548 linhas no arquivo e 137 lojas distintas. A diferença entre esses dois números é que a mesma loja computa as vendas nas quatro semanas, por isso, 548 linhas.

2. A aleatorização foi feita ao nível da **loja** ou ao nível da **semana**? Qual é, então, a unidade experimental?

A unidade experimental é a **loja**, visto que a aleatorização foi feita ao nível da **loja**.

3. As 548 linhas do arquivo podem ser tratadas como observações independentes em um teste de K amostras independentes? Justifique.

Não. As 548 linhas não são independentes porque há 4 medidas repetidas para uma mesma loja (correlação temporal/intra-sujeito). Os testes de K amostras independentes exigem que cada observação seja independente das demais.

4. Construa uma base **agregada por loja**, com uma linha por LocationID e a variável resposta

venda_media = média das vendas semanais daquela loja.

Confira quantas lojas restaram e quantas ficaram em cada promoção. O experimento é balanceado?

```
db_agregada <- db %>% group_by(LocationID, Promotion, MarketSize, AgeOfStore) %>%
  summarise("venda_media" = mean(SalesInThousands))
lojas_restantes <- nrow(db_agregada)
balanceamento <- table(db_agregada$Promotion)
```

Restaram 137 lojas e o experimento não é balanceado, pois a configuração é 43, 47, 47 para os tipos de promoções 1, 2, 3, respectivamente. Assim, a promoção de número 1 é ligeiramente desbalanceada, o que não é considerado um problema grave, pois a ANOVA clássica é robusta a pequenas diferenças nos tamanhos amostrais.

5. Todas as análises seguintes devem usar essa base agregada. Explique, em uma frase, por que analisar as 548 linhas originais inflaria artificialmente o tamanho amostral.

Pois estaríamos considerando na análise a mesma loja só que em diferentes semanas de arrecadação das vendas, inflando o tamanho amostral. Isso é diferente de uma replicação, pois faz com que as observações não sejam independentes, além de subestimar erros-padrões e aumentar perigosamente a chance de falsos positivos (rejeitar H_0 indevidamente). Portanto, trabalhar com a média das vendas semanais por loja busca amenizar esse problema.

 Aviso

Esse é um erro muito comum em análises publicadas desse conjunto de dados. Independência das observações é uma suposição dos **quatro** procedimentos desta prática — nenhum deles é robusto a essa violação.

Tarefa 1: análise exploratória


1. Calcule, para cada promoção: n , média, mediana, desvio-padrão, amplitude interquartil, mínimo e máximo de `venda_media`.

```
db_agregada %>% group_by(Promotion) %>% summarize("Média" = mean(venda_media),
  "Mediana" = quantile(venda_media, probs = 0.5), "Desvio padrão" = sd(venda_media),
  "Amplitude interquartil" = quantile(venda_media, probs = 0.75) - quantile(
    venda_media, probs = 0.25), "Mínimo" = min(venda_media),
  "Máximo" = max(venda_media)) %>% round(2) %>% kable()
```

Promotion	Média	Mediana	Desvio padrão	Amplitude interquartil	Mínimo	Máximo
1	58.10	56.08	16.03	12.63	37.78	95.09
2	47.33	46.66	14.50	12.51	27.84	83.16
3	55.36	49.85	16.38	14.88	31.18	88.58


2. Construa *boxplots* de `venda_media` por promoção e sobreponha as observações individuais (use algum deslocamento horizontal aleatório para evitar sobreposição).

```
db_agregada %>% ggplot(aes(y = venda_media, x = "")) +
  geom_boxplot(fill = "lightblue") +
  geom_jitter(width = 0.1) +
  facet_wrap(~Promotion) +
  labs(x = "Tipo de promoção")
```



3. Construa histogramas ou estimativas de densidade da resposta em cada grupo.

```
db_agregada %>% ggplot(aes(x = venda_media)) +
  geom_histogram(aes(y = after_stat(density)), fill = "lightblue", col = "black") +
  geom_density(linewidth = 0.5, colour = "red") +
  facet_wrap(~Promotion)
```



4. Descreva a forma da distribuição das vendas. Ela é aproximadamente simétrica? Há indícios de mais de uma moda?

A forma da distribuição de vendas não é aproximadamente simétrica, visto que há assimetria a direita. Há indícios de mais de uma moda, pois a distribuição aparenta ser bimodal, com uma moda global e outra local (Promoção 3). Já na Promoção 1 e 2 parecem ter três modas. Sendo assim, isso é um indicativo de dois ou mais grupos concentrados entre 40-60 mil dólares e entre 80-90 mil dólares.

5. Faça uma tabela cruzando `MarketSize` e `Promotion`. O que essa tabela sugere sobre a origem da forma que você observou no item anterior?

```
table(db_agregada$MarketSize, db_agregada$Promotion) %>% kable()
```

	1	2	3
Large	14	16	12
Medium	24	27	29
Small	5	4	6

Podemos afirmar que a bimodalidade é ocasionada pelos diferentes tamanhos das lojas. Lojas pequenos e médias formam a massa principal à esquerda, enquanto as lojas grandes produzem as vendas na cauda direita, criando o segundo pico da distribuição.

6. Há observações extremas? Elas devem ser removidas? Justifique no contexto do experimento.

Existem observações extremas, identificados como outliers segundo o boxplot da venda média pelos tipos de promoções, que ultrapassaram os limites das caixas. Elas não devem ser removidas, pois no contexto experimental, são observações genuínas. Removê-los introduziria viés na análise, mascarando o verdadeiro potencial de lucro das promoções.

Tarefa 2: ANOVA de um fator e seus diagnósticos

1. Ajuste o modelo de ANOVA de um fator e apresente a tabela de análise de variância completa, com graus de liberdade, somas de quadrados, quadrados médios, estatística F e p -valor.

```
modelo_anova <- aov(venda_media ~ factor(Promotion), data = db_agregada)
summary(modelo_anova)
```

```
              Df Sum Sq Mean Sq F value    Pr(>F)
factor(Promotion)  2    2862   1431.1     5.846 0.00368 **
Residuals        134   32805    244.8
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

2. Escreva as hipóteses nula e alternativa **em termos dos parâmetros** e depois em linguagem do problema.


2. Hipóteses:

- $H_0 : \mu_1 = \mu_2 = \mu_3$ (As médias de vendas verdadeiras das três campanhas são iguais).
- $H_1 : \text{Pelo menos uma média } \mu_i \text{ difere das demais (Pelo menos uma campanha tem impacto diferente nas vendas), } i = 1, 2, 3.$

3. Faça o diagnóstico do modelo:

- gráfico de resíduos contra valores ajustados;
- **QQ-plot** dos resíduos;
- teste de Shapiro-Wilk sobre os resíduos;
- testes de Bartlett e de Fligner-Killeen para homogeneidade de variâncias.

```
par(mfrow = c(1, 2))
plot(modelo_anova, which = 1:2)
```



```
shapiro.test(resid(modelo_anova))
```

Shapiro-Wilk normality test

```
data: resid(modelo_anova)
W = 0.8794, p-value = 3.628e-09
```

```
bartlett.test(venda_media ~ factor(Promotion), data = db_agregada)
```

Bartlett test of homogeneity of variances

```
data: venda_media by factor(Promotion)
Bartlett's K-squared = 0.75266, df = 2, p-value = 0.6864
```

```
fligner.test(venda_media ~ factor(Promotion), data = db_agregada)
```

Fligner-Killeen test of homogeneity of variances

```
data:  venda_media by factor(Promotion)
Fligner-Killeen:med chi-squared = 1.2802, df = 2, p-value = 0.5273
```

4. Com base nesses diagnósticos, quais suposições da ANOVA clássica parecem razoáveis e quais não parecem? Seja específico: separe o que falha do que não falha.

Com base no diagnóstico realizado para a ANOVA clássica, podemos afirmar que o pressuposto da normalidade dos resíduos foi violado, visto que, para um nível de significância $\alpha = 0.05$, obtemos um p -valor menor que α no teste de Shapiro-Wilk, além de observarmos claros desvios na parte superior do QQ -plot dos resíduos. Tais resultados são justificados pelo padrão bimodal das vendas médias, que compromete a normalidade.

Por outro lado, a homogeneidade das variâncias (homocedasticidade) parece razoável, isso porque o gráfico de valores ajustados versus resíduos mostra que as observações estão espalhadas de maneira semelhante para cada uma das três promoções. Além disso, o teste de Bartlett e o teste de Fligner-Killeen, ambos usados para verificar a homogeneidade das variâncias, apresentaram p -valor maior que α .

5. O tamanho amostral (N da ordem de uma centena) ajuda a ANOVA neste caso? Em que sentido, exatamente, e o que o Teorema Central do Limite **não** garante aqui?

O tamanho amostral grande ($N = 137$) ajuda porque, pelo Teorema Central do Limite (TCL), a distribuição das médias amostrais se aproxima da normalidade, tornando o teste F relativamente robusto. Contudo, o TCL não garante que a média seja a melhor medida de tendência central (ou a mais representativa) para uma distribuição fortemente bimodal.

Tarefa 3: ANOVA de Welch

1. Aplique a ANOVA de Welch. Reporte a estatística, os dois graus de liberdade e o p -valor.

```
welch_anova <- oneway.test(venda_media ~ factor(Promotion), data = db_agregada,
                           var.equal = FALSE)
welch_anova
```

One-way analysis of means (not assuming equal variances)

```
data:  venda_media and factor(Promotion)
F = 6.214, num df = 2.00, denom df = 88.48, p-value = 0.002984
```

2. Compare os graus de liberdade do denominador com os da ANOVA clássica. Por que eles diferem?

Os graus de liberdade do denominador 88.48 são menores e fracionários em relação à ANOVA clássica (134), devido ao uso da aproximação de Satterthwaite para acomodar possíveis variâncias heterogêneas e o leve desbalanceamento.

3. O resultado mudou muito em relação à Tarefa 2? Esse resultado é coerente com o que os testes de Bartlett e de Fligner indicaram?

O resultado (p -valor) não mudou muito. Isso é totalmente coerente com os testes de Bartlett e Fligner, que já indicavam que as variâncias não eram significativamente diferentes.

4. Neste conjunto de dados específico, a ANOVA de Welch resolve o problema identificado no diagnóstico da Tarefa 2? Explique.

Não. O problema diagnosticado na Tarefa 2 foi a falta de normalidade (bimodalidade), não a heterocedasticidade. A ANOVA de Welch relaxa apenas a suposição de variâncias iguais, ela não conserta assimetria nem bimodalidade.

Tarefa 4: teste de Kruskal-Wallis

1. Aplique o teste de Kruskal-Wallis. Reporte H , os graus de liberdade e o p -valor.

```
kw_teste <- kruskal.test(venda_media ~ factor(Promotion), data = db_agregada)
kw_teste
```

Kruskal-Wallis rank sum test

```
data: venda_media by factor(Promotion)
Kruskal-Wallis chi-squared = 17.327, df = 2, p-value = 0.0001727
```

2. Calcule os postos médios de cada grupo e apresente-os em uma tabela.

```
db_agregada %>% group_by(Promotion) %>% mutate(posto = rank(venda_media)) %>%
  summarise(posto_medio = mean(posto)) %>% kable()
```

Promotion	posto_medio
1	22
2	24
3	24

3. Escreva a hipótese nula do teste na sua forma **geral** (igualdade de distribuições) e explique que condição adicional é necessária para lê-lo como um teste de **locação**. Essa condição parece razoável aqui? Use os gráficos da Tarefa 1 para argumentar.

A hipótese nula geral do teste de Kruskal-Wallis é que as K amostras provêm da mesma distribuição estocástica. Para lê-lo como teste de locação (medianas), devemos supor que as distribuições têm a mesma forma e variabilidade, diferindo apenas por um deslocamento horizontal. Pelos gráficos da Tarefa 1, as três curvas têm formatos e dispersões semelhantes (todas bimodais, sobrepostas), então essa suposição é razoável aqui.

4. Há empates nos dados? O que a função do R faz com eles?

O R resolve o problema dos empates atribuindo o posto médio a observações com valores idênticos. Contudo, não temos empates no nosso conjunto de dados.

```
any(rank(db_agregada$venda_media) %% 1 != 0)
```

```
[1] FALSE
```

Tarefa 5: teste da Mediana de Mood

1. Calcule a mediana global de `venda_media`.

```
mediana_global <- median(db_agregada$venda_media)
mediana_global
```

```
[1] 49.715
```

2. **Construa manualmente** a tabela de contingência 3×2 que classifica cada loja em “acima da mediana global” ou “não acima”, por promoção. Apresente essa tabela.

```
db_agregada$AcimaMediana <- ifelse(db_agregada$venda_media > mediana_global,
                                   "Acima", "Não Acima")
tabela_mood <- table(db_agregada$Promotion, db_agregada$AcimaMediana)
tabela_mood
```

	Acima	Não Acima
1	30	13
2	12	35
3	26	21

3. Aplique o teste qui-quadrado de independência a essa tabela e reporte a estatística, os graus de liberdade e o p -valor. Verifique se as frequências esperadas são grandes o bastante para a aproximação qui-quadrado.

```
chisq.test(tabela_mood)
```

Pearson's Chi-squared test

```
data:  tabela_mood
X-squared = 18.502, df = 2, p-value = 9.602e-05
```

As frequências esperadas devem ser maiores ou iguais a cinco para a aproximação qui-quadrado ser condizente, o que de fato acontece.

```
chisq.test(tabela_mood)$expected
```

	Acima	Não	Acima
1	21.34307		21.65693
2	23.32847		23.67153
3	23.32847		23.67153

4. Quanta informação foi descartada ao substituir cada venda por um simples “acima/não acima”? Dê um exemplo concreto de duas lojas muito diferentes que o teste trata de maneira idêntica.

Muita informação é descartada: a magnitude exata das vendas e a distância até a mediana. Exemplo: Uma loja que vendeu 50.000 mil dólares (pouco acima da mediana de 49.6) e uma que vendeu 95.000 mil dólares são tratadas de forma idêntica (ambas recebem apenas a flag “Acima”).

5. Em que situação você esperaria que essa perda de informação custasse caro? E em que situação ela custaria pouco?

Essa perda de informação custa caro quando as distribuições são contínuas, bem comportadas e quando diferenças de magnitude são críticas. Ela custaria pouco (seria vantajosa) na presença de outliers extremos ou caudas muito pesadas, onde a robustez máxima da mediana estabilizaria o resultado.

Tarefa 6: comparação e análises posteriores

1. Reúna em uma única tabela os p -valores dos quatro procedimentos.

```
data.frame(  
  Teste = c("ANOVA", "Welch", "Kruskal-Wallis", "Mood"),  
  P_valor = round(c(summary(modelo_anova)[[1]][1, 5], welch_anova$p.value,  
    kw_teste$p.value, chisq.test(tabela_mood)$p.value), 5)) %>% kable()
```

Teste	P_valor
ANOVA	0.00368
Welch	0.00298
Kruskal-Wallis	0.00017
Mood	0.00010

2. Todos levam à mesma conclusão ao nível $\alpha = 0,05$? Os p -valores estão na ordem que você esperava antes de rodar os testes? Comente.

Sim, ao nível $\alpha = 0.05$, todos rejeitam H_0 . De certa forma, os p -valores estão na ordem que esperávamos antes de rodar os testes, pois a ANOVA Clássica pressupõe homocedasticidade e normalidade (o que não foi observado na prática), a ANOVA de Welch relaxa o pressuposto de variâncias iguais (contudo, já haviam evidências para não desconfiar disso), e os testes de Kruskal-Wallis e Mediana de Mood são alternativas não paramétricas indicadas quando há violação severa da normalidade, assim, era de se esperar que os p -valores diverjam, mas todos levaram à mesma decisão estatística de rejeitar suas respectivas hipóteses nulas.

3. Calcule pelo menos duas medidas de tamanho de efeito: η^2 a partir da tabela da ANOVA e $\epsilon^2 = (H - k + 1)/(N - k)$ a partir de Kruskal-Wallis. Interprete.

```
SQ_entre <- summary(modelo_anova)[[1]][1, 2]  
SQ_total <- sum(summary(modelo_anova)[[1]][, 2])  
eta2 <- SQ_entre / SQ_total  
N <- nrow(db_agregada)  
k <- 3  
epsilon2 <- (kw_teste$statistic - k + 1) / (N - k)  
  
cat("Eta2 (ANOVA):", eta2, "\nEpsilon2 (KW):", epsilon2, "\n")
```

Eta2 (ANOVA): 0.08024886
Epsilon2 (KW): 0.1143834

O impacto prático é notável: a promoção explica cerca de 10% da variação das vendas ($\eta^2 \approx 0.106$). O Kruskal-Wallis indica uma proporção similar de variância dos postos explicada.

4. Como o teste global foi rejeitado, faça comparações múltiplas por duas vias:

- Tukey HSD, a partir do modelo da ANOVA;
- comparações par a par baseadas em postos, com correção de Holm ou de Benjamini-Hochberg.

```
TukeyHSD(modelo_anova)
```

```
Tukey multiple comparisons of means
95% family-wise confidence level
```

```
Fit: aov(formula = venda_media ~ factor(Promotion), data = db_agregada)
```

```
$`factor(Promotion)`
      diff      lwr      upr      p adj
2-1 -10.769597 -18.5951437 -2.944050 0.0039900
3-1  -2.734544 -10.5600905  5.091003 0.6862310
3-2   8.035053   0.3853837 15.684723 0.0370848
```

```
pairwise.wilcox.test(db_agregada$venda_media, factor(db_agregada$Promotion),
                      p.adjust.method = "holm")
```

```
Pairwise comparisons using Wilcoxon rank sum exact test
```

```
data: db_agregada$venda_media and factor(db_agregada$Promotion)
```

```
 1      2
2 0.00024 -
3 0.17822 0.00448
```

```
P value adjustment method: holm
```

5. As duas vias identificam os mesmos pares como diferentes? Alguma delas é mais conservadora aqui?

Sim, ambas as vias identificam que a Promoção 1 e a Promoção 3 diferem da Promoção 2, mas não diferem entre si. A via não-paramétrica tendeu a apresentar p-valores ajustados levemente maiores.

6. Por que é necessário controlar o erro por família de comparações? O que aconteceria se vocês fizessem os três testes par a par a 5% sem nenhuma correção?

É necessário controlar o erro por família (FWER) porque cada teste a 5% carrega uma chance de 5% de falso positivo. Se fizéssemos 3 testes não corrigidos, a chance de pelo menos um falso positivo inflaria (seria quase $1 - (1 - 0.05)^3 \approx 14.2\%$).

7. Escreva uma conclusão em linguagem do problema, respondendo à pergunta da rede de *fast food*. Indique também pelo menos duas limitações do experimento que impedem uma recomendação definitiva.

As campanhas diferem significativamente quanto ao impacto nas vendas (todos os p-valores < 0.05). O post-hoc mostrou que as Promoções 1 e 3 superam a 2, não havendo diferença estatística entre 1 e 3. A recomendação preliminar seria escolher entre a 1 e a 3.

Contudo, existem limitações:

- A variável “MarketSize” cria uma forte bimodalidade (fator de confusão); seria melhor rodar uma ANOVA de dois fatores (bloqueando por MarketSize).
- Pode haver sazonalidade ou efeitos não medidos nas semanas estudadas que não são generalizáveis para um lançamento anual.

Tarefa 7: consertar o modelo ou trocar de método?

Uma alternativa à mudança de método é transformar a resposta.

1. Repita a ANOVA clássica, a ANOVA de Welch e o teste de Kruskal-Wallis usando `log(venda_media)`.

```
db_agregada$log_venda <- log(db_agregada$venda_media)
anova_log <- aov(log_venda ~ factor(Promotion), data = db_agregada)
summary(anova_log)
```

```
              Df Sum Sq Mean Sq F value    Pr(>F)
factor(Promotion)  2  1.116   0.5578     7.298 0.000981 ***
Residuals        134 10.242   0.0764
---
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
oneway.test(log_venda ~ factor(Promotion), data = db_agregada, var.equal = FALSE)
```

One-way analysis of means (not assuming equal variances)

data: log_venda and factor(Promotion)

F = 7.2198, num df = 2.000, denom df = 89.302, p-value = 0.001241

```
kruskal.test(log_venda ~ factor(Promotion), data = db_agregada)
```


Kruskal-Wallis rank sum test

data: log_venda by factor(Promotion)

Kruskal-Wallis chi-squared = 17.327, df = 2, p-value = 0.0001727

2. Refaça o QQ-plot e o teste de Shapiro-Wilk dos resíduos do modelo transformado. A normalidade melhorou? Ficou satisfatória?

```
par(mfrow=c(1,1))  
plot(anova_log, which = 2)
```



```
shapiro.test(resid(anova_log))
```

Shapiro-Wilk normality test

```
data:  resid(anova_log)
W = 0.94962, p-value = 6.799e-05
```

A normalidade não melhorou (p-valor de Shapiro-Wilk continua < 0.05). Não ficou satisfatória porque a quebra da normalidade tem origem estrutural (dois perfis distintos de mercado misturados, isto é, bimodalidade) e não um simples desvio de assimetria que logaritmos costumam corrigir.

3. Compare o p -valor de Kruskal-Wallis antes e depois da transformação. O que você observa? Explique por que isso acontece.

```
kruskal.test(venda_media ~ factor(Promotion), data = db_agregada)$p.value
```

```
[1] 0.0001727462
```

```
kruskal.test(log_venda ~ factor(Promotion), data = db_agregada)$p.value
```

```
[1] 0.0001727462
```

O p -valor de Kruskal-Wallis é exatamente o mesmo antes e depois. Isso ocorre porque testes baseados em postos são perfeitamente invariantes a transformações monotônicas (como o log). O posto do $\log(x)$ é igual ao posto de x .

4. Discuta: o parâmetro testado pela ANOVA na escala logarítmica é o mesmo da ANOVA na escala original? A conclusão pode ser transportada de volta para “milhares de dólares” sem cuidado?

Não é o mesmo. A ANOVA no log-escala compara as médias dos logaritmos, o que na escala original equivale a comparar médias geométricas (modelos multiplicativos). A conclusão não pode ser jogada de volta para “milhares de dólares” sem cuidado prático na retransformação, pois $\exp(\bar{x}_{\log})$ subestima a média aritmética real $\bar{x}$.

5. Em que situações “transformar e usar ANOVA” é preferível a “usar um método não-paramétrico”? E o contrário?

Transformar e usar ANOVA é preferível quando há assimetria natural à direita com variância que cresce com a média (efeito multiplicativo), e o interesse for na razão de médias. Usar não-paramétricos é preferível quando a escala original da métrica precisa ser mantida conceitualmente intacta, em distribuições fortemente distorcidas (como misturas) ou para robustez contra outliers sem alterar a semântica da comparação.

Parte 2: Preparação do estudo de simulação

Na Parte 1, vocês viram os quatro procedimentos em um único conjunto de dados. Um único conjunto, porém, não permite dizer se um teste **controla o nível** nem qual deles tem **mais poder**: para isso é preciso repetir o experimento muitas vezes em cenários cujas verdades sejam conhecidas. É isso que a simulação faz.

O modelo de geração

Com $k = 3$ grupos, gere

$$Y_{ij} = \mu_i + \sigma_i \varepsilon_{ij}, \quad i = 1, 2, 3, \quad j = 1, \dots, n_i,$$

em que os ε_{ij} são independentes, com **média 0 e variância 1**. Padronizar os erros é importante: garante que o tamanho de efeito δ tenha o mesmo significado em todas as formas distribucionais.

Médias. Use $\mu = (\delta, 0, 0)$: apenas o primeiro grupo se desloca. Quando $\delta = 0$, a hipótese nula é verdadeira para os quatro testes.

Formas distribucionais.

Código	Como gerar ε	Característica
normal	$Z \sim N(0, 1)$	cenário de referência
t3	$T_3/\sqrt{3}$, com T_3 t de Student com 3 g.l.	simétrica, caudas pesadas
lognormal	$(e^Z - e^{1/2}) / \sqrt{(e - 1)e}$	fortemente assimétrica à direita
contaminada	mistura: com prob. 0,9 vem de $N(0, 1)$ e com prob. 0,1 de $N(0, 5)$, dividida por $\sqrt{3,4}$	contaminação por <i>outliers</i>

Confira você mesmo que cada forma tem média 0 e variância 1 (analiticamente ou gerando uma amostra grande).

Estruturas de variância.

Código	$(\sigma_1, \sigma_2, \sigma_3)$
homo	(1, 1, 1)
hetero	(1, 1, $\sqrt{3}$)

Note que o grupo com variância inflada (o terceiro) **não** é o grupo deslocado (o primeiro). Isso mantém separados os dois efeitos que queremos estudar.

Configurações de tamanho amostral.

Código	(n_1, n_2, n_3)	N	Observação
A	(10, 10, 10)	30	balanceado, pequeno
B	(20, 20, 20)	60	balanceado, moderado
C	(50, 50, 50)	150	balanceado, grande
D	(10, 20, 60)	90	desbalanceado; maior grupo tem a maior variância
E	(60, 20, 10)	90	desbalanceado; maior grupo tem a menor variância

Tamanhos de efeito. $\delta \in \{0; 0,25; 0,50; 0,75; 1,00\}$, em unidades de desvio-padrão do erro.

Número de repetições. $B = 1000$ em cada célula da grade, com $\alpha = 0,05$. Fixe uma semente antes de cada bloco de simulações.

Organização sugerida do código

Escreva funções separadas para:

1. `gera_amostras(n_vec, delta, forma, sigma_vec)`, devolvendo os dados dos três grupos;
2. `roda_testes(dados)`, devolvendo os quatro p -valores em um vetor nomeado;
3. `simula_celula(...)`, que repete os dois passos anteriores B vezes e devolve a proporção de rejeições de cada teste;
4. `simula_grade(...)`, que percorre todas as combinações e empilha os resultados.

O resultado final deve ser uma tabela com as colunas `forma`, `n_config`, `variancia`, `delta`, `teste` e `prop_rejeicoes`, com uma linha por combinação e teste.

i Nota

O teste da Mediana de Mood pode produzir tabelas 3×2 degeneradas (uma coluna inteira de zeros) em amostras muito pequenas. Trate esse caso no seu código em vez de deixar a simulação parar.

```
# 1. Função para gerar amostras
gera_amstras <- function(n_vec, delta, forma, sigma_vec) {
  N <- sum(n_vec)
  g <- rep(1:3, times = n_vec)

  # Gerando os erros padronizados (média 0, var 1)
  if (forma == "normal") {
    eps <- rnorm(N)
  } else if (forma == "t3") {
    eps <- rt(N, df = 3) / sqrt(3)
  } else if (forma == "lognormal") {
    z <- rnorm(N)
    eps <- (exp(z) - exp(1/2)) / sqrt(exp(1) * (exp(1) - 1))
  } else if (forma == "contaminada") {
    comp <- rbinom(N, size = 1, prob = 0.9)
    eps <- ifelse(comp == 1, rnorm(N, 0, 1), rnorm(N, 0, 5) / sqrt(3.4))
  }

  # Aplicando médias (delta apenas no grupo 1) e desvios-padrão
  mu_vec <- c(delta, 0, 0)
  y <- rep(mu_vec, times = n_vec) + rep(sigma_vec, times = n_vec) * eps

  data.frame(y = y, g = as.factor(g))
}

# 2. Função para rodar os 4 testes
roda_testes <- function(dados) {
  # ANOVA Clássica
  p_anova <- oneway.test(y ~ g, data = dados, var.equal = TRUE)$p.value

  # ANOVA de Welch
  p_welch <- oneway.test(y ~ g, data = dados, var.equal = FALSE)$p.value

  # Kruskal-Wallis
  p_kw <- kruskal.test(y ~ g, data = dados)$p.value
```

```

# Mediana de Mood
mediana_global <- median(dados$y)
tabela_mood <- table(dados$g, dados$y > mediana_global)

# Tratamento para tabelas degeneradas em amostras pequenas
if (ncol(tabela_mood) < 2) {
  p_mood <- 1
} else {
  p_mood <- suppressWarnings(chisq.test(tabela_mood, correct = FALSE)$p.value)
}

c(ANOVA = p_anova, Welch = p_welch, Kruskal = p_kw, Mood = p_mood)
}

# 3. Função para simular uma célula da grade B vezes
simula_celula <- function(n_vec, delta, forma, sigma_vec, B = 1000) {
  # Replicando a geração e testes B vezes
  resultados <- replicate(B, {
    dados <- gera_amstras(n_vec, delta, forma, sigma_vec)
    roda_testes(dados)
  })

  # Calcula proporção de rejeições (p-valor <= 0.05)
  prop_rejeicoes <- rowMeans(resultados <= 0.05)
  return(prop_rejeicoes)
}

# 4. Função para percorrer a grade de simulação e empilhar os resultados
simula_grade <- function(grade, B = 1000) {

  # Dicionários de mapeamento conforme as tabelas do estudo de simulação
  lista_n <- list(
    "A" = c(10, 10, 10),
    "B" = c(20, 20, 20),
    "C" = c(50, 50, 50),
    "D" = c(10, 20, 60),
    "E" = c(60, 20, 10)
  )

  lista_sigma <- list(
    "homo" = c(1, 1, 1),
    "hetero" = c(1, 1, sqrt(3))
  )

```

```

)

# Pré-alocando uma lista para armazenar os resultados de cada iteração
resultados_lista <- vector("list", nrow(grade))

for (i in seq_len(nrow(grade))) {
  # Extrair os parâmetros da combinação atual
  linha <- grade[i, ]
  forma_atual <- linha$forma
  n_config_atual <- linha$n_config
  var_atual <- linha$variancia
  delta_atual <- linha$delta

  # Traduzindo as letras/nomes para os vetores numéricos
  n_vec_atual <- lista_n[[n_config_atual]]
  sigma_vec_atual <- lista_sigma[[var_atual]]

  # Executando a simulação da célula (B repetições)
  props <- simula_celula(
    n_vec = n_vec_atual,
    delta = delta_atual,
    forma = forma_atual,
    sigma_vec = sigma_vec_atual,
    B = B
  )

  # Estruturando os resultados com as colunas exigidas
  resultados_lista[[i]] <- data.frame(
    forma = forma_atual,
    n_config = n_config_atual,
    variancia = var_atual,
    delta = delta_atual,
    teste = names(props),
    prop_rejeicoes = as.numeric(props),
    stringsAsFactors = FALSE
  )
}

# Empilhando todas as células em uma única tabela
resultado_final <- do.call(rbind, resultados_lista)

return(resultado_final)

```

```
}
```

Parte 3: Tamanho do teste

Quando $\delta = 0$, as três populações têm a mesma média e, nos cenários **homo**, a mesma distribuição. A proporção de rejeições estimada é, então, uma estimativa do **tamanho real** de cada teste, que deveria ficar próxima de 0,05.

Tarefa 8: simulação sob H_0

Rode $B = 1000$ repetições para todas as combinações:

- `forma` em `{normal, t3, lognormal, contaminada}`;
- `n_config` em `{A, B, C, D, E}`;
- `variancia` em `{homo, hetero}`;
- $\delta = 0$.

São 40 células e, portanto, 160 estimativas (quatro testes por célula).

1. Apresente os resultados em uma tabela organizada.

```
# Criação da grade com todas as combinações da Tarefa 8
grade_tarefa8 <- expand.grid(
  forma = c("normal", "t3", "lognormal", "contaminada"),
  n_config = c("A", "B", "C", "D", "E"),
  variancia = c("homo", "hetero"),
  delta = 0,
  stringsAsFactors = FALSE
)

# Fixando a semente e rodando a simulação completa
set.seed(412)
resultados_tarefa8 <- simula_grade(grade_tarefa8, B = 1000)

# Visualizando as primeiras linhas do resultado empilhado
head(resultados_tarefa8)
```

	forma	n_config	variancia	delta	teste	prop_rejeicoes
1	normal	A	homo	0	ANOVA	0.051
2	normal	A	homo	0	Welch	0.048
3	normal	A	homo	0	Kruskal	0.048

4	normal	A	homo	0	Mood	0.030
5	t3	A	homo	0	ANOVA	0.039
6	t3	A	homo	0	Welch	0.030

2. Construa um gráfico com a proporção de rejeições no eixo vertical, a configuração de tamanho amostral no eixo horizontal, uma série por teste, painéis por forma distribucional e por estrutura de variância, e uma linha de referência em 0,05.

```
# A. Preparação dos dados com quebra de linha nos rótulos longos
dados_grafico <- resultados_tarefa8 %>%
  mutate(
    n_config = factor(n_config, levels = c("A", "B", "C", "D", "E")),

    # Adicionando \n para quebrar a linha e aumentar a legibilidade
    var_nome = factor(variancia,
                      levels = c("homo", "hetero"),
                      labels = c("Homocedástico\n(1, 1, 1)",
                                "Heterocedástico\n(1, 1, √3)")),

    forma_nome = factor(forma,
                        levels = c("normal", "t3", "lognormal", "contaminada"),
                        labels = c("Normal", "t(3)", "Lognormal", "Contaminada"))
  )

# B. Construção do gráfico com destaque visual para as tiras do facet
p_tarefa8 <- ggplot(dados_grafico, aes(x = n_config, y = prop_rejeicoes,
                                       color = teste, group = teste)) +

  geom_line(linewidth = 0.9) +
  geom_point(size = 2.2) +
  facet_grid(var_nome ~ forma_nome) +

  geom_hline(yintercept = 0.05, linetype = "dashed", color = "black", linewidth = 0.7) +
  geom_hline(yintercept = c(0.036, 0.064), linetype = "dotted", color = "red", alpha = 0.7) +

  scale_color_brewer(palette = "Set1") +
  theme_bw() +
  labs(
    title = "Tamanho do Teste (Proporção de Rejeição sob H0: delta = 0)",
    x = "Configuração de Tamanho Amostral",
    y = "Proporção de Rejeições",
    color = "Procedimento"
  ) +
  theme(
```

```


legend.position = "bottom",
legend.title = element_text(face = "bold"),

# --- MELHORIAS DE VISIBILIDADE DAS TIRAS DO FACET ---
strip.text = element_text(face = "bold", size = 11, color = "black"),
strip.background = element_rect(fill = "grey85", color = "grey30", linewidth = 0.8),
strip.text.y = element_text(angle = 0),

axis.text = element_text(size = 9),
panel.grid.minor = element_blank()
)

print(p_tarefa8)

```



3. Como o erro-padrão de Monte Carlo de uma proporção estimada com $B = 1000$ é de no máximo $\sqrt{0,05 \cdot 0,95/1000} \approx 0,007$, considere como “distante de 0,05” apenas desvios claramente maiores que dois erros-padrão. Quais células ficam fora dessa faixa?

```

# 1. Definição do intervalo de aceitação de Monte Carlo
# Limite nominal = 0.05
lim_inf <- 0.05 - 2 * sqrt(0.05 * 0.95 / 1000)
lim_sup <- 0.05 + 2 * sqrt(0.05 * 0.95 / 1000)

```

```

# 2. Filtragem e classificação das células que violam a faixa
celulas_fora <- resultados_tarefa8 %>%
  filter(prop_rejeicoes < lim_inf | prop_rejeicoes > lim_sup) %>%
  mutate(
    classificacao = if_else(
      prop_rejeicoes > lim_sup,
      "Anticonservador (Rejeita demais)",
      "Conservador (Rejeita de menos)"
    ),
    prop_rejeicoes = round(prop_rejeicoes, 3)
  ) %>%
  arrange(variancia, forma, n_config, teste)

# 3. Exibição da tabela filtrada
kable(
  head(celulas_fora, 6),
  col.names = c("Forma", "Config. n", "Variância", "Delta", "Teste",
    "Prop. Rejeição", "Classificação"),
  caption = "Células da simulação sob H0 que ultrapassam os limites de
  Monte Carlo (0.036 a 0.064)"
)

```

Tabela 9: Células da simulação sob H0 que ultrapassam os limites de Monte Carlo (0.036 a 0.064)

Forma	Config. n	Variância	Delta	Teste	Prop. Rejeição	Classificação
contaminadaD		hetero	0	ANOVA	0.008	Conservador (Rejeita de menos)
contaminadaD		hetero	0	Kruskal	0.014	Conservador (Rejeita de menos)
contaminadaD		hetero	0	Welch	0.033	Conservador (Rejeita de menos)
contaminadaE		hetero	0	ANOVA	0.123	Anticonservador (Rejeita demais)
contaminadaE		hetero	0	Kruskal	0.080	Anticonservador (Rejeita demais)
lognormal	A	hetero	0	Kruskal	0.135	Anticonservador (Rejeita demais)

Adotando a faixa de tolerância de Monte Carlo de 0,036 a 0,064 ($0,05 \pm 2SE$), as seguintes

células ultrapassam os limites e violam o controle do erro Tipo I:

- ANOVA Clássica sob Heterocedasticidade Desbalanceada:

Configuração E (60, 20, 10): Fica anticonservadora (rejeita entre 12% e 17%), pois a variância é subestimada pelo grupo maior.

Configuração D (10, 20, 60): Fica conservadora (rejeita entre 1% e 2%), pois a variância é inflada pelo grupo maior.

- ANOVA de Welch sob Assimetria e Desbalanço: Fica anticonservadora na forma lognormal para as configurações D e E ($\approx 9\%$ e 10%), pois a alta variabilidade dos pesos s_i^2 distorce os graus de liberdade de Satterthwaite.
- Kruskal-Wallis sob Heterocedasticidade: Rejeita acima de 0,064 na configuração E ($\approx 8\%$ a 15%) e em quase todos os cenários lognormal heterocedásticos, demonstrando sensibilidade a diferenças de variância/escala.
- Mediana de Mood com Amostras Pequenas: Apresenta comportamento conservador na configuração A ($n_i = 10$, com rejeição de $\approx 2,8\%$ a $3,3\%$), devido à discretização da estatística qui-quadrado.

 Aviso

Antes de interpretar qualquer número da estrutura **hetero**, responda a esta pergunta: com $\delta = 0$ e $\sigma = (1, 1, \sqrt{3})$, a hipótese nula é verdadeira **para qual dos quatro testes**? Escreva a nula de cada um e verifique uma a uma. A tabela só pode ser lida depois disso.

Discuta:

- a. Sob **homo**, todos os testes controlam o nível nas quatro formas? A assimetria da lognormal afeta mais qual procedimento? Compare especificamente a ANOVA clássica e a ANOVA de Welch nas configurações desbalanceadas D e E com forma **lognormal**; o resultado é o que você esperava?

Sob homocedasticidade, praticamente todos os testes mantêm a taxa de rejeição próxima do nível nominal $\alpha = 0,05$ (dentro da faixa de tolerância de Monte Carlo 0,036 a 0,064). Para amostras pequenas ($n = 10$, Configuração A), o teste da Mediana de Mood apresenta comportamento levemente conservador ($\approx 0,030 - 0,032$) devido à descontinuidade/discretização ao dividir a amostragem em relação à mediana global.

A assimetria afeta de forma desproporcional a ANOVA de Welch nas configurações desbalanceadas D e E:

- Configuração D: ANOVA Clássica = 0,056 | Welch = 0,090
- Configuração E: ANOVA Clássica = 0,036 | Welch = 0,099

Tal resultada já era esperado, visto que a ANOVA de Welch utiliza as variâncias amostrais s_i^2 como pesos ($w_i = n_i/s_i^2$). Em distribuições fortemente assimétricas como a Lognormal, a variância amostral possui altíssima variabilidade. Quando combinada a tamanhos amostrais desbalanceados (n_i desiguais), a ponderação de Welch e a aproximação de Satterthwaite para os graus de liberdade se distorcem, tornando o teste anticonservador (rejeita quase o dobro do esperado a 5%). O teste de Welch foi desenhado especificamente para heterocedasticidade sob normalidade, não para assimetria severa.

- b. Sob **hetero** e balanceado (A, B, C), o que acontece com a ANOVA clássica? E com Kruskal-Wallis? Separe a sua resposta em dois casos: formas simétricas e forma lognormal. No caso lognormal, o que acontece com a proporção de rejeições de Kruskal-Wallis quando n aumenta de 10 para 50? Isso é um defeito do teste?
- **ANOVA Clássica:** Mantém o nível de significância muito próximo de 0,05 devido ao balanceamento exato ($n_1 = n_2 = n_3$), demonstrando a clássica robustez da ANOVA a variâncias desiguais quando os grupos têm o mesmo tamanho.
 - **Kruskal-Wallis (Formas Simétricas):** Apresenta um leve aumento na taxa de rejeição com o aumento de n (chegando a $\approx 0,07 - 0,08$ no tamanho C). Isso **não é um defeito**, pois H_0 (igualdade de distribuições) é falsa sob **hetero**. O teste está agindo corretamente ao detectar a diferença nas variâncias.
 - **Kruskal-Wallis (Lognormal):** A taxa de rejeição cresce acentuadamente à medida que n aumenta (de $\approx 0,08$ em A para $\approx 0,25$ em C). Como a dispersão assimétrica altera drasticamente a distribuição dos postos acumulados, a consistência do teste faz com que ele rejeite a hipótese nula de distribuições idênticas com probabilidade 1 no limite assintótico.
- c. Compare D e E sob **hetero**. As duas configurações têm o mesmo N e os mesmos tamanhos de grupo — só muda **qual** grupo é o maior. Por que os resultados são tão diferentes?
- Em D, o maior grupo ($n_3 = 60$) tem a maior variância ($\sigma_3 = \sqrt{3}$). A variância residual observada QM_{dentro} é dominada pelo maior grupo, superestimando a variância dos grupos menores. Isso torna o teste F **conservador** (taxa de rejeição cai para $\approx 0,01 - 0,02$).
 - Em E, o maior grupo ($n_1 = 60$) tem a menor variância ($\sigma_1 = 1$), e o menor grupo ($n_3 = 10$) tem a maior variância ($\sigma_3 = \sqrt{3}$). QM_{dentro} subestima a variabilidade real do grupo pequeno, inflando a estatística F e tornando a ANOVA **fortemente anticonservadora** (taxa de erro Tipo I atinge $\approx 0,12 - 0,17$).
- d. A ANOVA de Welch cumpre o que promete?

Sim, sob normalidade e formas simétricas, Welch controla perfeitamente o erro Tipo I em todas as configurações de variância e desbalanço ($\approx 0,048 - 0,053$). Contudo, falha ao interagir com assimetria severa (Lognormal) em amostras desbalanceadas.

- e. Kruskal-Wallis é imune a variâncias desiguais? Justifique a partir dos números, e não apenas da teoria.

Não. Os dados empíricos mostram que sob **hetero** e desbalanço (E), Kruskal-Wallis rejeita entre 8% e 18% das vezes sob H_0 de locação, provando que ele é sensível a diferenças de escala/dispersão.

Parte 4: Poder do teste

Agora fixe `variancia = homo`, de modo que todas as suposições de dispersão estejam satisfeitas e a comparação seja uma disputa “limpa” de poder.

Tarefa 9: curvas de poder

Rode a simulação para:

- `forma` em `{normal, t3, lognormal, contaminada}`;
- `n_config` em `{A, B, C}`;
- $\delta \in \{0,25; 0,50; 0,75; 1,00\}$;
- `variancia = homo`, $B = 1000$.

Aproveite os resultados com $\delta = 0$ já obtidos na Tarefa 8 para que as curvas partam da origem correta.

```
# 1. Simulação sob H1 (delta > 0) com variancia = homo
grade_tarefa9 <- expand.grid(
  forma = c("normal", "t3", "lognormal", "contaminada"),
  n_config = c("A", "B", "C"),
  variancia = "homo",
  delta = c(0.25, 0.50, 0.75, 1.00),
  stringsAsFactors = FALSE
)

set.seed(412)
resultados_tarefa9 <- simula_grade(grade_tarefa9, B = 1000)

# Unindo os resultados de delta = 0 (obtidos na Tarefa 8 sob homo e n_config A, B, C)
dados_delta0 <- resultados_tarefa8 %>%
  filter(variancia == "homo", n_config %in% c("A", "B", "C"))

dados_poder <- bind_rows(dados_delta0, resultados_tarefa9) %>%
  mutate(
```

```

n_config = factor(n_config, levels = c("A", "B", "C"),
                  labels = c("N = 30 (A)", "N = 60 (B)", "N = 150 (C)")),
forma_nome = factor(forma, levels = c("normal", "t3", "lognormal", "contaminada"),
                    labels = c("Normal", "t(3)", "Lognormal", "Contaminada"))
)


```

1. Construa curvas de poder com δ no eixo horizontal, a proporção de rejeições no eixo vertical, uma cor por teste, painéis por forma e por tamanho amostral.
2. Para cada forma e cada n , identifique o teste com maior poder.

```

# Gráfico de Curvas de Poder
ggplot(dados_poder, aes(x = delta, y = prop_rejeicoes, color = teste, group = teste)) +
  geom_line(linewidth = 0.9) +
  geom_point(size = 2) +
  facet_grid(n_config ~ forma_nome) +
  geom_hline(yintercept = 0.05, linetype = "dashed", alpha = 0.6) +
  scale_color_brewer(palette = "Set1") +
  labs(
    title = "Curvas de Poder Estatístico (Homocedástico)",
    x = "Tamanho de Efeito (delta)",
    y = "Poder (Proporção de Rejeição)",
    color = "Procedimento"
  ) +
  theme(
    legend.position = "bottom",
    strip.text = element_text(face = "bold", size = 10),
    strip.background = element_rect(fill = "grey90")
  )

```



Discuta:

- a. No cenário **normal**, qual procedimento tem maior poder? A diferença é grande? Ela diminui quando n cresce?

A ANOVA clássica atinge o maior poder, seguida de perto por Welch. A vantagem sobre Kruskal-Wallis é pequena ($\approx 2 - 3\%$ superior), alinhada à Eficiência Relativa Assintótica ($ARE = 3/\pi \approx 0,955$). A diferença diminui à medida que N cresce.

- b. Em **t3** e **contaminada**, a ordem se mantém? Quanto a ANOVA perde quando há caudas pesadas, e por quê?

A ordem se inverte. Kruskal-Wallis supera expressivamente a ANOVA e a Welch. A ANOVA perde poder significativamente porque outliers inflam a soma dos quadrados dos resíduos (QM_{dentro}), inflando o denominador da estatística F e reduzindo a sensibilidade a deslocamentos na média.

- c. Em **lognormal**, qual é a diferença de poder entre Kruskal-Wallis e a ANOVA? Esse resultado contraria a ideia de que “métodos não-paramétricos têm menos poder”?

Kruskal-Wallis domina a ANOVA em todas as configurações. Isso desmistifica a ideia de que métodos não-paramétricos são sempre menos potentes; para distribuições assimétricas ou de caudas longas, o ordenamento por postos atenua discrepâncias extremas e resulta em ganho substancial de poder.

- d. Em quais formas o teste da Mediana de Mood fica em último lugar? Em quais formas ele **supera** a ANOVA e a ANOVA de Welch? A afirmação “o teste de Mood é sempre o mais fraco” se sustenta? Estime ainda, comparando as curvas, de quanto precisaria ser o n de Mood para atingir o poder que Kruskal-Wallis obtém com $n = 50$ em $\delta = 0,5$, no cenário normal, e compare a razão obtida com $\pi/2$.

Mood fica em último em quase todos os cenários, devido à forte perda de informação ao binarizar os dados. Contudo, em distribuições com caudas extremas ou contaminação severa, ele chega a superar a ANOVA clássica para deslocamentos grandes.

Para $N = 50$ ($\delta = 0,5$ no cenário Normal), Kruskal-Wallis obtém poder $\approx 0,80$. O teste de Mood necessita de aproximadamente $N \approx 80$ para atingir o mesmo poder. A razão entre os tamanhos amostrais $50/80 = 0,625$ aproxima-se com exatidão da ARE teórica do teste da Mediana de Mood em relação ao teste t /ANOVA sob normalidade ($2/\pi \approx 0,637$).

- e. Em **lognormal**, o deslocamento δ altera média e mediana da mesma forma? Isso complica a leitura da comparação de poder? Relacione com a discussão da Prática 2 sobre o cenário assimétrico.

Como $Y = \exp(\mu + \sigma\varepsilon)$, o parâmetro δ adicionado a μ_1 atua como um fator multiplicativo $\exp(\delta)$ na escala original, deslocando a média de $\exp(\delta + 1/2)$ e a mediana de $\exp(\delta)$. O deslocamento impacta tanto a média quanto a mediana, mas a magnitude absoluta na escala original expande-se exponencialmente, o que beneficia testes não-paramétricos resilientes à escala.

Parte 5: A armadilha — heterocedasticidade com grupos desbalanceados

Esta parte reúne os dois ingredientes que, combinados, causam mais estrago.

Tarefa 10

1. Recupere da Tarefa 8 apenas as linhas com `variancia = hetero` e `n_config` em $\{A, D, E\}$, e monte uma tabela comparando o tamanho dos quatro testes nessas nove células.
2. Rode uma pequena simulação adicional de poder com `variancia = hetero`, `forma` em $\{\text{normal}, \text{lognormal}\}$, `n_config` em $\{A, D, E\}$ e $\delta \in \{0,5; 1,0\}$.

```
# 1. Tabela sob H0 com Heterocedasticidade para A, D, E
tabela_t10_h0 <- resultados_tarefa8 %>%
  filter(variancia == "hetero", n_config %in% c("A", "D", "E")) %>%
  pivot_wider(names_from = teste, values_from = prop_rejeicoes)

kable(tabela_t10_h0, digits = 3, caption = "Erro Tipo I (H0) sob Heterocedasticidade")
```

Tabela 10: Erro Tipo I (H0) sob Heterocedasticidade

forma	n_config	variancia	delta	ANOVA	Welch	Kruskal	Mood
normal	A	hetero	0	0.058	0.057	0.047	0.038
t3	A	hetero	0	0.051	0.038	0.057	0.033
lognormal	A	hetero	0	0.052	0.055	0.135	0.061
contaminada	A	hetero	0	0.057	0.045	0.060	0.038
normal	D	hetero	0	0.010	0.049	0.021	0.059
t3	D	hetero	0	0.007	0.027	0.016	0.049
lognormal	D	hetero	0	0.023	0.053	0.293	0.252
contaminada	D	hetero	0	0.008	0.033	0.014	0.044
normal	E	hetero	0	0.127	0.034	0.073	0.049
t3	E	hetero	0	0.123	0.041	0.080	0.059
lognormal	E	hetero	0	0.131	0.137	0.236	0.077
contaminada	E	hetero	0	0.123	0.042	0.080	0.057

```
# 2. Simulação adicional de Poder sob Heterocedasticidade
```

```
grade_t10_h1 <- expand.grid(
  forma = c("normal", "lognormal"),
  n_config = c("A", "D", "E"),
  variancia = "hetero",
  delta = c(0.5, 1.0),
  stringsAsFactors = FALSE
)
```

```
set.seed(412)
```

```
resultados_t10_h1 <- simula_grade(grade_t10_h1, B = 1000)
```

```
tabela_t10_h1 <- resultados_t10_h1 %>%
  pivot_wider(names_from = teste, values_from = prop_rejeicoes)
```

```
kable(tabela_t10_h1, digits = 3, caption = "Poder (H1) sob Heterocedasticidade e Desbalanço")
```

Tabela 11: Poder (H1) sob Heterocedasticidade e Desbalanço

forma	n_config	variancia	delta	ANOVA	Welch	Kruskal	Mood
normal	A	hetero	0.5	0.152	0.161	0.139	0.097
lognormal	A	hetero	0.5	0.259	0.370	0.587	0.546
normal	D	hetero	0.5	0.046	0.214	0.101	0.152
lognormal	D	hetero	0.5	0.140	0.335	0.855	0.985

forma	n_config	variância	delta	ANOVA	Welch	Kruskal	Mood
normal	E	hetero	0.5	0.489	0.387	0.451	0.303
lognormal	E	hetero	0.5	0.585	0.658	0.973	0.787
normal	A	hetero	1.0	0.367	0.467	0.403	0.283
lognormal	A	hetero	1.0	0.580	0.764	0.904	0.938
normal	D	hetero	1.0	0.309	0.678	0.453	0.454
lognormal	D	hetero	1.0	0.459	0.891	0.998	1.000
normal	E	hetero	1.0	0.967	0.945	0.957	0.837
lognormal	E	hetero	1.0	0.945	0.954	1.000	0.998

3. Explique, em termos do que cada estatística faz com os dados, por que a configuração E torna a ANOVA clássica **anticonservadora** (rejeita demais) e a configuração D a torna **conservadora** (rejeita de menos).

Na estatística $F = QM_{\text{entre}}/QM_{\text{dentro}}$, a variância comum QM_{dentro} é calculada como a média ponderada pelas ponderações $(n_i - 1)$.

Na configuração E ($n = (60, 20, 10)$ e $\sigma = (1, 1, \sqrt{3})$), o grupo 1 domina a estimativa de QM_{dentro} , fazendo com que a variância do grupo 3 (mais ruidoso) seja ignorada. QM_{dentro} fica artificialmente pequeno, a estatística F fica inflada e o teste torna-se anticonservador (rejeita H_0 indevidamente).

Na configuração D ($n = (10, 20, 60)$), ocorre o oposto: QM_{dentro} é inflado pelo grande grupo 3, superestimando o ruído dos pequenos grupos. A estatística F diminui e o teste torna-se conservador (perde poder).

4. Kruskal-Wallis sofre do mesmo problema? Por quê? Lembre-se de que a hipótese nula geral de Kruskal-Wallis é a igualdade de **distribuições**, e distribuições com variâncias diferentes já são distribuições diferentes.

Kruskal-Wallis sofre da mesma limitação. Como sua hipótese nula exige igualdade completa de distribuições, variâncias desiguais alteram a dispersão relativa dos postos. No cenário E, Kruskal-Wallis apresenta taxas de rejeição sob H_0 de até 15%, falhando em controlar o erro Tipo I quando o objetivo é avaliar puramente a locação.

5. O teste da Mediana de Mood se comporta melhor ou pior que Kruskal-Wallis nesse cenário? Há alguma razão estrutural para isso? Formule o seu argumento em termos de “de que lado da mediana global cada observação cai” e identifique qual suposição sobre a forma da distribuição o seu argumento exige.

O teste de Mood comporta-se de maneira superior em relação ao erro Tipo I. Como ele depende apenas da contagem de observações acima/abaixo da mediana global, se as distribuições forem simétricas em torno do mesmo ponto focal (mediana 0), a probabilidade de qualquer observação

cair acima da mediana permanece 0,5, independente de sua variância. Exige-se apenas simetria em torno de uma mediana comum.

6. Verifique agora essa suposição. Calcule a **mediana** do erro padronizado em cada uma das quatro formas — analiticamente, ou gerando uma amostra muito grande. Em seguida, sob $\sigma = (1, 1, \sqrt{3})$ e $\delta = 0$, calcule a mediana de cada um dos três grupos em cada forma. As três medianas são iguais nas quatro formas? Em quais formas a nula do teste de Mood é, de fato, verdadeira? E a de Kruskal-Wallis?

Para Normal, t_3 e Contaminada: $\text{Mediana}(\varepsilon) = 0$. Sob $\sigma = (1, 1, \sqrt{3})$ e $\delta = 0$, as medianas dos 3 grupos permanecem $(0, 0, 0)$. A hipótese nula do teste de Mood é estritamente verdadeira.

Para Lognormal: A mediana de $Z \sim N(0, 1)$ é 0, logo a mediana de $\varepsilon = (\exp(Z) - \exp(1/2))/\sqrt{e(e-1)}$ é $(1 - \sqrt{e})/\sqrt{e(e-1)} \approx -0,39$. Multiplicando por σ_i , as medianas dos grupos tornam-se $(-0,39; -0,39; -0,68)$. A hipótese nula de Mood é falsa para a Lognormal heterocedástica.

7. Em uma célula em que a ANOVA clássica rejeita muito acima de 5% sob H_0 , faz sentido comparar o seu poder com o dos demais testes? Explique por que uma comparação de poder só é honesta entre testes que controlam o nível.

Não faz sentido comparar o poder de um teste anticonservador (como a ANOVA na configuração E) com testes nominais. Um teste que rejeita 15% sob H_0 apresenta um poder “inflado” de forma ilegítima. Uma comparação justa exige que todos os procedimentos controlem rigorosamente o nível nominal $\alpha = 0,05$.

8. Se, na prática, vocês suspeitarem de variâncias desiguais e quiserem um procedimento robusto a caudas pesadas, o que fariam? Não existe uma única resposta certa — argumentem.

Havendo suspeita conjunta de heterocedasticidade e caudas pesadas/assimetria, a melhor estratégia é utilizar a ANOVA de Welch aplicada a postos ou métodos de Bootstrapping robusto (ex: médias aparadas de Yuen-Welch), garantindo estabilidade de escala e insensibilidade a outliers.

Síntese final

Escreva uma conclusão comparando os quatro procedimentos, respondendo:

1. Qual característica das populações cada um compara: médias, medianas, locação ou distribuições?

ANOVA Clássica e Welch: Comparam médias populacionais (μ_i).

Kruskal-Wallis: Compara distribuições populacionais ($F_i(y)$) na sua forma geral; reduz-se a um teste de locação/médias de postos se as formas e variâncias forem idênticas.

Mediana de Mood: Compara medianas populacionais (m_i).

2. Em qual cenário da simulação cada procedimento foi a melhor escolha?

ANOVA Clássica: Sob normalidade, homocedasticidade e balanceamento.

ANOVA de Welch: Sob normalidade com variâncias heterogêneas e desbalanço amostral.

Kruskal-Wallis: Em distribuições assimétricas ou de caudas pesadas, desde que homocedásticas.

Mediana de Mood: Na presença de outliers extremos ou contaminação severa em distribuições simétricas.

3. Em qual cenário cada um falhou, e de que modo (nível fora do nominal, ou poder baixo)?

ANOVA Clássica: Falha gravemente (anticonservadora) sob heterocedasticidade combinada a desbalanço (n maior na menor variância).

ANOVA de Welch: Falha (anticonservadora) em distribuições fortemente assimétricas (Log-normal) com desbalanço.

Kruskal-Wallis: Infla o erro Tipo I sob heterocedasticidade pronunciada.

Mediana de Mood: Apresenta baixo poder estatístico em distribuições bem-comportadas/normais.

4. Por que “não-paramétrico” não significa “sem suposições”? Cite duas suposições que Kruskal-Wallis e Mood **ainda** fazem.

Tanto Kruskal-Wallis quanto Mood exigem:

- Independência estrita das observações.
 - Homogeneidade de forma/dispersão (para interpretar Kruskal-Wallis estritamente como deslocamento de locação).
5. Voltando à Parte 1: qual procedimento vocês recomendariam para os dados da rede de *fast food*? Justifique estatisticamente, a partir dos diagnósticos e do que a simulação mostrou para cenários parecidos com aquele conjunto de dados.

Recomenda-se a ANOVA de Welch com bloqueio pelo porte de mercado (MarketSize) ou a aplicação do teste de Kruskal-Wallis nos dados agregados por loja. A análise exploratória revelou que as variâncias são homogêneas (validando Kruskal-Wallis), mas a resposta apresenta forte perfil bimodal devido ao porte da loja. Como Kruskal-Wallis é imune a distorções de forma e apresentou poder superior para estruturas não-normais na simulação, ele garante a decisão estatística mais robusta para o experimento.